

Sistem de Predicție a Vârstei din Imagini RMN

Lucrare de Licență - Universitatea POLITEHNICA din București

Despre Proiect

Acest proiect reprezintă o soluție bazată pe învățare profundă (Deep Learning) pentru estimarea vârstei biologice cerebrale a pacienților, pornind de la volume RMN structurale (T1-weighted). Modelul este capabil să definească traiectoria normală de îmbătrânire a creierului, învățând trăsături anatomice dintr-un set masiv de pacienți sănătoși (OpenBHB).

Diferența dintre vârsta prezisă de model și vârsta cronologică reală (cunoscută sub numele de *Brain Age Gap*) funcționează ca un biomarker cantitativ. O vârstă cerebrală semnificativ mai mare decât cea cronologică poate semnală o îmbătrânire accelerată, asociată frecvent cu afecțiuni neurodegenerative.

Setul de Date

S-a utilizat datasetul public **OpenBHB** (Open Big Healthy Brains), conținând scanări de la peste 3.600 de pacienți. Datele sunt în format *quasiraw* și sunt preprocesate înainte de antrenare.

- Dimensiune volume brute:** 182 x 218 x 182 voxeli.
- Procesare:** Redimensionare, eliminare outlieri (percentile 1-99), normalizare z-score.
- Dimensiune finală pentru rețea:** 107 x 128 x 107 voxeli.

Arhitectura Modelului

Soluția folosește o arhitectură **ResNet-SE 3D**, personalizată pentru date volumetrice.

- Convoluții 3D:** Extrag caracteristici din întregul volum cerebral simultan.
- Conexiuni Reziduale (ResNet):** Permit antrenarea unor rețele adânci rezolvând problema disparității gradientilor.
- Blocuri Squeeze-and-Excitation (SE):** Adaugă un mecanism de atenție pe canale, permițând modelului să se concentreze pe regiunile cerebrale cu cea mai mare relevanță predictivă.

Performanțe și Rezultate

În faza de testare pe un set de validare independent (757 pacienți), modelul a obținut următoarele performanțe după 27 de epoci de antrenare:

Eroarea Medie Absolută (MAE)	Deviație Standard Eroare	Eroare Mediană	Subiecți cu Eroare < 5 ani
3.86 ani	3.89 ani	2.84 ani	72.3%

După aplicarea unei tehnici de corecție liniară pentru *regression dilution bias*, performanța globală a crescut la un MAE de **3.39 ani**.

Instrucțiuni de Rulare

Proiectul este structurat integral sub forma unui Jupyter Notebook (proiect-de-diploma.ipynb). Nu există scripturi .py separate, toți pașii fiind executați secvențial direct din celulele notebook-ului.

- **Pasul 1: Încărcarea mediului.** Deschideți notebook-ul în VS Code (asigurați-vă că aveți extensia Jupyter instalată) sau încărcați-l pe o platformă cloud de dezvoltare (ex. Kaggle, Google Colab).
- **Pasul 2: Conectarea datelor.** Dacă rulați pe Kaggle (mediul nativ al proiectului), asigurați-vă că seturile de date RMN (variantele aferente competiției/proiectului OpenBHB) sunt atașate mediului de lucru din secțiunea Data.
- **Pasul 3: Execuția.** Din meniul de sus al editorului, rulați celulele de sus în jos (sau folosiți opțiunea *Run All*). Notebook-ul conține secțiuni logice delimitate clar:
 - Setarea enviroment-ului și limitarea warning-urilor de TensorFlow.
 - Preprocesarea și normalizarea datelor RMN.
 - Definirea arhitecturii ResNet-SE 3D și antrenarea distribuită.
 - Evaluarea performanțelor și aplicarea corecției statistice de bias.

Tehnologii Utilizate

- **Limbaaj:** Python 3
- **Framework-uri ML:** TensorFlow / Keras, Scikit-Learn
- **Procesare date:** NumPy, Pandas, SciPy
- **Infrastructură:** Kaggle cu accelerare GPU (ex. T4 x2 via MirroredStrategy)